

CC3092 DEEP LEARNING Y SISTEMAS INTELIGENTES

Competencia de modelación con Multi-Layer Perceptron

Predicción de SalePrice en Ames Housing

RMSE CV: 26,847.57 +/- 3,545.49 USD

Javier Valladares

Agosto de 2026

Resumen ejecutivo

Se desarrolló un MLP para regresión sobre 1,168 viviendas y 80 predictores. La configuración se seleccionó sin consultar el holdout, mediante exploración, 17 trials de Optuna (5 podados) y una confirmación estratificada de cinco folds. El modelo ganador redujo el RMSE CV de 36,873.49 a 26,847.57 USD (27.2%); en el holdout interno independiente obtuvo 17,754.33 USD. El artefacto de competencia se reentrenó después con todas las observaciones disponibles. Todas las métricas se calcularon en la escala original de SalePrice.

Criterio de lectura de las métricas

El RMSE penaliza de forma cuadrática los errores grandes. Por ello, una diferencia entre CV y holdout puede aparecer cuando cambia la concentración de viviendas de precio alto. El RMSE del artefacto final no se estima sobre las mismas filas usadas en su reentrenamiento; la cifra honesta procede del modelo entrenado solo con el 80% de desarrollo.

1. Análisis exploratorio de datos (EDA)

1.1 Dimensiones, tipos y objetivo

El CSV contiene 1,168 observaciones y 81 columnas: Id, 36 predictores numericos, 43 categóricos y SalePrice. No hay filas ni Id duplicados. MSSubClass (15 códigos de tipo constructivo) y MoSold (12 meses) son números por almacenamiento, pero semánticamente son categorías; OverallQual y OverallCond se conservaron como escalas ordinales numéricas.

Estadístico	SalePrice (USD)
Media	181,441.54
Mediana	165,000.00
Desviación estándar	77,263.58
Mínimo	34,900
Máximo	745,000
Asimetría	1.743




Figura 1. SalePrice original y transformado con $\log_{1p}$.

La media supera a la mediana y el máximo alcanza 745,000 USD, evidencia de una cola derecha pronunciada. Esto justificó probar $\log_{1p}$, pero la transformación final se decidió por RMSE original, no por simetría visual.

1.2 Valores faltantes, atípicos e inconsistencias

Variable	Faltantes	%
PoolQC	1162	99.5%
MiscFeature	1122	96.1%
Alley	1094	93.7%
Fence	935	80.1%
MasVnrType	683	58.5%
FireplaceQu	547	46.8%
LotFrontage	217	18.6%
GarageType	64	5.5%
GarageYrBlt	64	5.5%
GarageFinish	64	5.5%

Existen 6,227 celdas faltantes repartidas en 19 columnas. En variables como PoolQC, Alley, Fence, chimenea, garage y sótano, la ausencia suele representar que el elemento no existe, por lo que se preservó como categoría explícita Missing. LotFrontage (18.6%) y las variables numéricas se imputaron con la mediana del fold y un indicador de ausencia. Electrical tiene un único faltante. No se eliminaron filas.




Figura 2. Porcentaje de valores faltantes por variable.

Los boxplots y scatterplots revelaron colas largas en LotArea, GrLivArea y superficies de sótano/garage. En vez de borrar observaciones posiblemente válidas, el pipeline ganador aprendió límites en los percentiles 1 y 99 dentro de cada fold. Esta decisión reduce la influencia de extremos sobre gradientes sin usar información de validación.

1.3 Relaciones con SalePrice

Variable	Correlación de Pearson
OverallQual	0.786
GrLivArea	0.696
GarageCars	0.641
GarageArea	0.624
TotalBsmtSF	0.598
1stFlrSF	0.588
FullBath	0.553
TotRmsAbvGrd	0.520
YearBuilt	0.517
YearRemodAdd	0.509

OverallQual (0.786) y GrLivArea (0.696) dominan las relaciones lineales, seguidas por capacidad/área de garage, sótano y primer piso. Las relaciones no son enteramente lineales: la dispersión aumenta en casas costosas y Neighborhood desplaza claramente la mediana del precio. La colinealidad entre medidas de área (GarageCars/GarageArea o 1stFlrSF/TotalBsmtSF) no obliga a eliminarlas en un MLP regularizado, pero si aumenta el riesgo de sobreajuste.




Figura 3. Mapa de correlaciones de las variables numéricas más relacionadas con SalePrice.




Figura 4. Relaciones de seis predictores principales con SalePrice.

1.4 Decisiones derivadas del EDA

- Categoricals: Missing explícito, one-hot, categorías infrecuentes agrupadas con `min_frequency=5` y tolerancia a niveles no vistos.
- Numerics: mediana e indicador de ausencia, clipping 1/99, `log1p` solo para columnas no negativas con asimetría absoluta mayor a 0.75 y `RobustScaler`.
- Ingeniería de variables: superficie total, baños equivalentes, porches, antigüedad al vender, tiempo desde remodelación e interacciones calidad-superficie.
- Objetivo: se compararon SalePrice original y `log1p`; el ganador usa escala original estandarizada durante entrenamiento.

2. Metodología de desarrollo

2.1 Separación y control de leakage

Se reservó 20% como holdout interno con `random_state=20260817` y estratificación por deciles de precio. El 80% restante se usó para exploración y Optuna con tres folds estratificados. Los tres candidatos más prometedores se reevaluaron en una partición nueva de cinco folds (seed 31415). Solo después de elegir el ganador se abrió el holdout. Imputadores, umbrales de asimetría, percentiles, escaladores, agrupación de categorías y one-hot se ajustaron exclusivamente en el train de cada fold.

2.2 Arquitectura y entrenamiento

Componente	Configuracion final
Arquitectura	512 -> 256 -> 128 -> 64 -> 1
Activacion	GELU
Dropout	0.1668
Normalización	Ninguna
Optimizador	Adam
Learning rate	0.0003244
Weight decay	0.0008082
Batch size	64
Loss	MSE sobre SalePrice estandarizado
Gradient clipping	Norma maxima 5.0
Scheduler	ReduceLROnPlateau, factor 0.5
Early stopping	Paciencia 50

PyTorch permitió controlar dropout, inicialización Kaiming, weight decay, clipping, scheduler y restauración del mejor checkpoint. Aunque MPS estaba disponible en el M1 Pro, CPU fue elegido por estabilidad y menor overhead en matrices pequeñas. La semilla global fue 42.

2.3 Búsqueda de hiperparámetros

Optuna con TPE exploró 17 trials y pudo 5 mediante MedianPruner. Se variaron profundidad/ancho, ReLU/GELU/LeakyReLU/SiLU, dropout, normalizacion, Adam/AdamW, learning rate, weight decay, batch size, target original/log1p, Standard/RobustScaler, clipping, umbral de asimetría, frecuencia minima e ingeniería de features. La métrica objetiva siempre fue RMSE tras invertir cualquier transformación del objetivo.

3. Resultados de iteraciones

Iteración / cambio	Arquitectura	Target	RMSE train	RMSE valid.
Baseline	128-64	raw	11,179	36,873
Objetivo log1p	128-64	log1p	18,761	44,354
Features + regularización	256-128-64	raw	18,893	32,302
Red profunda sin regularizar	512-256-128-64	raw	8,021	33,963
Robust + regularización	256-256-128	raw	11,631	29,494

Iteración / cambio	Arquitectura	Target	RMSE train	RMSE valid.
Ganador Optuna 3-fold	512-256-128-64	raw	12,301	28,865
Ganador confirmado 5-fold	512-256-128-64	raw	12,786	26,848
Alternativa robusta 5-fold	256-256-128	raw	11,821	28,297

Fuente: *experiments/results.csv*, generado automáticamente por ejecuciones reales.

La mejora total contra el baseline fue de 10,025.92 USD (27.2%). La red profunda sin regularización alcanzó RMSE train de 8,021 pero CV de 33,963, evidencia de sobreajuste. El baseline log1p empeoró a 44,354: simetrizar el target no alineó la loss con la penalización absoluta del RMSE oficial. RobustScaler, clipping, weight decay y dropout estabilizaron el entrenamiento; Optuna encontró después una red mayor con GELU que mejoró nuevamente en los cinco folds de confirmación.




Figura 5. Curvas representativas del MLP baseline.




Figura 6. Curvas representativas del modelo ganador en CV.

El mejor número de épocas varió entre 34 y 57; la mediana fue 37. Esa mediana, determinada sin el holdout, se usó para reentrenar el artefacto final sobre las 1,168 filas.

4. Discusión de resultados

4.1 Generalización y complejidad

La CV confirmatoria fue 26,847.57 +/- 3,545.49 USD y el holdout independiente 17,754.33 USD. El holdout favorable no reemplaza la CV: contiene solo 234 casos y su composición produce una estimación más optimista. La selección se basa por tanto en la media de cinco folds. El gap train-CV del ganador (12,786 vs. 26,848) muestra capacidad suficiente y sobreajuste residual, pero menor inestabilidad que la red profunda sin regularización.

4.2 Análisis de errores

Segmento	n	RMSE	MAE	Sesgo real-pred.
Bajo	59	13,012	9,159	-5,850
Medio-bajo	58	13,031	9,197	-771
Medio-alto	58	12,528	10,197	-764
Alto	59	27,562	20,892	6,182

Los tres cuartiles inferiores tienen RMSE entre 12,528 y 13,031 USD, mientras el cuartil alto sube a 27,562. El sesgo de +6,182 en casas caras indica subestimación; en el segmento bajo el sesgo negativo indica sobreestimación. Este patron es coherente con regresión hacia la media y con menos ejemplos en la cola del precio.

Id	Real	Predicho	Error abs.	Neighborhood
1182	392,500	341,064	51,436	Crawfor
1108	274,725	223,988	50,737	Gilbert
525	315,750	297,554	18,196	NoRidge
2	181,500	198,956	17,456	Veenker
330	78,000	95,314	17,314	IDOTRR




Figura 7. Diagnóstico del holdout: ajuste, residuos y error por segmento.

El error medio absoluto fue 12,384.06 USD y el sesgo global -296.81 USD, cercano a cero. Los mayores errores se concentran en propiedades caras o poco comunes; no se observa un desplazamiento global fuerte, pero si heterocedasticidad: la amplitud de los residuos aumenta con la predicción.

4.3 Limitaciones

- Solo hay 1,168 observaciones para unas 300 columnas procesadas; la varianza entre folds sigue siendo material.
- One-hot produce alta dimensionalidad y un MLP no incorpora de forma natural las particiones inductivas favorables de modelos de árbol para datos tabulares.
- Las colas de precio y los vecindarios raros tienen poca representación; el RMSE enfatiza precisamente esos errores grandes.
- La búsqueda de 17 trials es seria pero no exhaustiva; más seeds y repeated CV reducirían incertidumbre a mayor costo computacional.

5. Conclusiones

El MLP final usa capas 512-256-128-64, GELU, dropout 0.167, Adam, learning rate 0.0003244, weight decay 0.0008082 y batch 64. Con preprocessing robusto e ingeniería de variables alcanzó 26,847.57 USD de RMSE CV, una reducción de 27.2% contra el baseline. El holdout de 17,754.33 USD confirma que el pipeline generaliza, aunque el desempeño es peor y más variable en viviendas del cuartil superior.

Los aprendizajes principales fueron: ajustar todo preprocessing dentro del fold, optimizar la métrica en escala original, regularizar redes profundas y confirmar los mejores trials con una partición distinta. Como mejoras futuras convendría repetir CV con más seeds, explorar embeddings categóricos, ensembles de MLPs con seeds distintas y una loss ponderada/calibración que reduzca la subestimación de propiedades caras, siempre validando el RMSE original.

6. Enlace al repositorio de GitHub

Código, artefacto final, resultados y pasos de reproducción: github.com/Javiervalladares1/ia-proyecto1-mlp-house-prices

El comando de competencia es `python predict.py test.csv`. El modelo, preprocesador, transformador del objetivo, orden de columnas, versiones, seed y metadatos se encuentran en `models/final/`.

Anexo A. Entregables reproducibles

Componente	Ubicación / comando
EDA	<code>run_eda.py</code> ; <code>artifacts/</code> ; <code>figures/</code>
Entrenamiento y búsqueda	<code>train.py</code> ; <code>experiments/results.csv</code> ; <code>experiments/optuna_trials.csv</code>
Modelo final	<code>models/final/model.pt</code> y artefactos <code>joblib/json</code>
Predicción	<code>predict.py test.csv</code>
Pruebas	<code>python -m unittest discover -s tests -v</code>
Informe	<code>reports/Informe_Proyecto_1_MLP.docx</code> y <code>.pdf</code>